

目次

1 比率の差の検定	2
1.1 どのような検定か	2
1.2 サンプルサイズの設計方法	3
1.2.1 両側検定の場合	3
1.2.2 片側検定の場合	4
2 Welch の t 検定	4
2.1 どのような検定か	4
2.2 サンプルサイズの設計	5
2.2.1 両側検定の場合	5
2.2.2 片側検定の場合	5
2.3 正規分布に従っていないデータに対する適用	5
3 ポアソン分布の差の検定	8
3.1 どのような検定か	8
3.2 サンプルサイズの設計	9
3.2.1 両側検定	9
3.2.2 片側検定	9
4 同等性検定	9
4.1 どのような検定か	9
4.2 サンプルサイズの設計	10
5 非劣性検定	11
5.1 どのような検定か	11
5.2 サンプルサイズの設計	11
6 マンホイットニーの U 検定	11
6.0.1 どのような検定か	11
6.0.2 サンプルサイズの計算	12
7 多重比較の補正	12
7.1 Holm 法	12
7.1.1 検定の方法	12
7.1.2 FWER を有意水準以下に抑えられることの証明	12
7.1.3 Bonferroni 法に対する優位性	13

1 比率の差の検定

1.1 どのような検定か

比率の差の検定は、AB テストにおいて、A 群と B 群の間で CVR に有意な差があるかを判定する場合に用いることができる。二項分布に従う確率変数 $X_1 \sim B(n_1, p_1)$, $X_2 \sim B(n_2, p_2)$ における母比率 p_1 と p_2 に違いがあるかを判断するための検定である。ここで、 n_1, n_2 は各群のサンプルサイズであり、 $n_2 = rn_1$ とする。また、

$$\hat{p}_1 = \frac{X_1}{n_1}, \quad \hat{p}_2 = \frac{X_2}{n_2} \quad (1.1)$$

とする。いま、 n_1, n_2 は十分大きく、中心極限定理より

$$\hat{p}_1 \sim N\left(p_1, \frac{p_1(1-p_1)}{n_1}\right), \quad \hat{p}_2 \sim N\left(p_2, \frac{p_2(1-p_2)}{n_2}\right) \quad (1.2)$$

が成り立つとする。これは、 X_k ($k = 1, 2$) が $B(1, p_k)$ に従う確率変数の和であることによる。このとき、 $\hat{\delta} = \hat{p}_1 - \hat{p}_2$ は正規分布の再生性より

$$\hat{\delta} \sim N\left(p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}\right) \quad (1.3)$$

となる。特に、帰無仮説 $H_0 : p_1 = p_2 (= p)$ が成り立つ時、

$$\hat{\delta} \sim N\left(0, p(1-p)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)\right) \quad (1.4)$$

である。 $\hat{p} = (X_1 + X_2)/(n_1 + n_2)$ として、

$$Z = \frac{\hat{\delta}}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \quad (1.5)$$

が検定統計量である。対立仮説に対する棄却域と p 値の計算方法は表 1.1 の通りである。 z は正規分布に従う確率変数であり、 z_α は上側 $100\alpha\%$ を満たす点である。

表 1.1: 比率の差の検定における対立仮説と棄却域、p 値の計算方法

対立仮説	棄却域	p 値の計算方法
$p_1 \neq p_2$	$ Z > z_{\alpha/2}$	$2P(z > Z)$
$p_1 > p_2$	$Z > z_\alpha$	$P(z > Z)$
$p_1 < p_2$	$Z < -z_\alpha$	$P(z < Z)$

1.2 サンプルサイズの設計方法

1.2.1 両側検定の場合

対立仮説を $p_1 \neq p_2$ としたときのサンプルサイズ設計に用いる計算式を導出する。対立仮説が成り立つとした時、

$$1 - \beta = P(|Z| > z_{\alpha/2}) = P(Z > z_{\alpha/2}) + P(Z < -z_{\alpha/2}) \quad (1.6)$$

である。ここで、 $p_1 > p_2$ とする。この時、式 (1.6) の第二項は十分小さいとして無視する。すると、以下のように整理できる。

$$1 - \beta = P(Z > z_{\alpha/2}) \quad (1.7)$$

$$= P\left(\frac{\hat{\delta}}{\sqrt{p(1-p)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} > z_{\alpha/2}\right) \quad (1.8)$$

$$= P\left(\frac{\hat{\delta} - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} > \frac{z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}}\right) \quad (1.9)$$

$$(1.10)$$

対立仮説が真である時に

$$\frac{\hat{\delta} - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \sim N(0, 1) \quad (1.11)$$

であるから、

$$-z_{\beta} = \frac{z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \quad (1.12)$$

が成り立つ。ここで、 $n_2 = rn_1$ を使って n_1 について解くと、

$$n_1 = \frac{\left(z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})} + z_{\beta}\sqrt{rp_1(1-p_1) + p_2(1-p_2)}\right)^2}{(p_1 - p_2)^2 r} \quad (1.13)$$

を得る。 $\hat{p} = (X_1 + X_2)/(n_1 + n_2)$ であったが、以下のように整理すれば n_1, n_2 に依存せず計算可能である。

$$\hat{p} = \frac{X_1 + X_2}{n_1 + n_2} = \frac{n_1\hat{p}_1 + n_2\hat{p}_2}{n_1 + n_2} = \frac{n_1\hat{p}_1 + rn_1\hat{p}_2}{n_1 + rn_1} = \frac{\hat{p}_1 + r\hat{p}_2}{1 + r} \quad (1.14)$$

$$(1.15)$$

上記の導出は $p_1 > p_2$ を仮定したが、 $p_1 < p_2$ を仮定した場合は

$$1 - \beta = P(Z < -z_{\alpha/2}) = P(Z > z_{\alpha/2}) \quad (1.16)$$

となるため、同じ計算式で良い。

1.2.2 片側検定の場合

対立仮説を $p_1 > p_2$ とした場合のサンプルサイズ設計に用いる計算式は、両側検定における計算式の $z_{\alpha/2}$ に z_α を代入すれば良い。式 (1.7) が変わるだけだからである。

2 Welch の t 検定

2.1 どのような検定か

Welch の t 検定は、AB テストにおいて、A 群と B 群の間でユーザー当たりの平均 CV 数に有意な差があるかを判定する場合に用いることができる。確率変数 $X_{1,i}$ ($i = 1, \dots, n_1$) $\sim N(\mu_1, \sigma_1^2)$ の母平均 μ_1 と、 $X_{2,i}$ ($i = 1, \dots, n_2$) $\sim N(\mu_2, \sigma_2^2)$ の母平均 μ_2 が異なるかを判断するための検定である。ここで、 n_1, n_2 は各群のサンプルサイズであり、 $n_2 = rn_1$ とする。また、 $\mathbb{E}[X_{1,i}] = \mu_1, \text{Var}[X_{1,i}] = \sigma_1^2, \mathbb{E}[X_{2,i}] = \mu_2, \text{Var}[X_{2,i}] = \sigma_2^2$ である。

Welch の t 検定における検定統計量は次の通りである。

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (2.1)$$

ここで、

$$\bar{X}_1 = \frac{1}{n} \sum_{i=1}^n X_{1,i} \quad (2.2)$$

$$\bar{X}_2 = \frac{1}{n} \sum_{i=1}^n X_{2,i} \quad (2.3)$$

$$s_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{1,i} - \bar{X}_1)^2 \quad (2.4)$$

$$s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{2,i} - \bar{X}_2)^2 \quad (2.5)$$

である。対立仮説に対する棄却域と p 値の計算方法は表 2.1 の通りである。 t は t 分布に従う確率変数であり、 $t_\alpha(\nu)$ は自由度 ν の t 分布において上側 $100\alpha\%$ を満たす点である。

表 2.1: t 検定における対立仮説と棄却域、p 値の計算方法

対立仮説	棄却域	p 値の計算方法
$\mu_1 \neq \mu_2$	$ T > t_{\alpha/2}(\nu)$	$2P(t > T)$
$\mu_1 > \mu_2$	$T > t_\alpha(\nu)$	$P(t > T)$
$\mu_1 < \mu_2$	$T < -t_\alpha(\nu)$	$P(t < T)$

2.2 サンプルサイズ的设计

2.2.1 両側検定の場合

対立仮説を $\mu_1 \neq \mu_2$ としたときのサンプルサイズ設計に用いる計算式を導出する。対立仮説が成り立つとした時、

$$1 - \beta = P(|T| > t_{\alpha/2}) = P(T > t_{\alpha/2}) + P(T < -t_{\alpha/2}) \quad (2.6)$$

である。ここで、 $\mu_1 > \mu_2$ とする。この時、式 (2.6) の第二項は十分小さいとして無視する。また、サンプルサイズが大きい時に検定統計量は標準正規分布に従う確率変数に分布収束することを利用し、以下のように整理する。

$$1 - \beta = P(T > z_{\alpha/2}) \quad (2.7)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} > z_{\alpha/2}\right) \quad (2.8)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} > z_{\alpha/2} - \frac{\mu_1 - \mu_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}\right) \quad (2.9)$$

これより、

$$-z_\beta = z_{\alpha/2} - \frac{\mu_1 - \mu_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (2.10)$$

が成り立つ。 $n_2 = rn_1$ を利用して n_1 について解くことで、サンプルサイズの計算式を得る。

$$n_1 = \frac{(z_{\alpha/2} + z_\beta)^2 \left(s_1^2 + \frac{s_2^2}{r}\right)}{(\mu_1 - \mu_2)^2} \quad (2.11)$$

2.2.2 片側検定の場合

両側検定の場合の計算式において、 $z_{\alpha/2}$ に z_α を代入すれば良い。

2.3 正規分布に従っていないデータに対する適用

AB テストにおいて、サンプルサイズが多い場合はデータの性質によらず、Welch の t 検定を用いて良いかを検討する。

$X_{1,1}, \dots, X_{1,n}$ が群 1、 $X_{2,1}, \dots, X_{2,n}$ が群 2 のサンプルであり、それぞれ群内で独立に同一分布に従うとする。また、群 1 と群 2 は独立であるとする。 $\mathbb{E}[X_{1,i}] = \mu_1$, $\text{Var}[X_{1,i}] = \sigma_1^2$, $\mathbb{E}[X_{2,i}] = \mu_2$, $\text{Var}[X_{2,i}] = \sigma_2^2$ とする ($\sigma_1^2, \sigma_2^2 \in (0, \infty)$)。

Welch の t 検定における検定統計量は

$$t = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2 + s_2^2}{n}}} \quad (2.12)$$

である（帰無仮説が真であることは仮定しない）。ここで、

$$\bar{X}_1 = \frac{1}{n} \sum_{i=1}^n X_{1,i} \quad (2.13)$$

$$\bar{X}_2 = \frac{1}{n} \sum_{i=1}^n X_{2,i} \quad (2.14)$$

$$s_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{1,i} - \bar{X}_1)^2 \quad (2.15)$$

$$s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{2,i} - \bar{X}_2)^2 \quad (2.16)$$

である。また、

$$U_n = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2 + \sigma_2^2}{n}}} \quad (2.17)$$

$$R_n = \sqrt{\frac{s_1^2 + s_2^2}{\sigma_1^2 + \sigma_2^2}} \quad (2.18)$$

とする。

U_n の分子は、

$$\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2) = \frac{1}{n} \sum_{i=1}^n ((X_{1,i} - \mu_1) - (X_{2,i} - \mu_2)) \quad (2.19)$$

と整理できる。ここで、 $W_i = (X_{1,i} - \mu_1) - (X_{2,i} - \mu_2)$ とおく。群 1 内の i.i.d. 性、群 2 内の i.i.d. 性、および群間独立性より、 $W_1, \dots, W_n$ も i.i.d. である。 W_i の期待値と分散はそれぞれ次のようになる。

$$\mathbb{E}[W_i] = \mathbb{E}[(X_{1,i} - \mu_1) - (X_{2,i} - \mu_2)] \quad (2.20)$$

$$= \mathbb{E}[X_{1,i}] - \mu_1 - \mathbb{E}[X_{2,i}] + \mu_2 \quad (2.21)$$

$$= 0 \quad (2.22)$$

$X_{1,i}$ と $X_{2,i}$ の独立性より、

$$\text{Var}[W_i] = \text{Var}[(X_{1,i} - \mu_1) - (X_{2,i} - \mu_2)] \quad (2.23)$$

$$= \text{Var}[X_{1,i}] + \text{Var}[X_{2,i}] \quad (2.24)$$

$$= \sigma_1^2 + \sigma_2^2 \quad (2.25)$$

これは正の有限値である。中心極限定理より、

$$U_n = \frac{\bar{W}}{\sqrt{\frac{\sigma_1^2 + \sigma_2^2}{n}}} = \frac{\sqrt{n}(\bar{W} - 0)}{\sqrt{\sigma_1^2 + \sigma_2^2}} \xrightarrow{d} Z \sim \mathcal{N}(0, 1) \quad (2.26)$$

となる。

一方、 R_n について、 $s_1^2 \xrightarrow{p} \sigma_1^2, s_2^2 \xrightarrow{p} \sigma_2^2$ が成り立つことを示す。 $k = 1, 2$ について、

$$\sum_{i=1}^n (X_{k,i} - \bar{X}_k)^2 = \sum_{i=1}^n ((X_{k,i} - \mu_k) - (\bar{X}_k - \mu_k))^2 \quad (2.27)$$

$$= \sum_{i=1}^n (X_{k,i} - \mu_k)^2 - 2(\bar{X}_k - \mu_k) \sum_{i=1}^n (X_{k,i} - \mu_k) + n(\bar{X}_k - \mu_k)^2 \quad (2.28)$$

となる。ここで、 $\sum_{i=1}^n (X_{k,i} - \mu_k) = n(\bar{X}_k - \mu_k)$ より、

$$\sum_{i=1}^n (X_{k,i} - \bar{X}_k)^2 = \sum_{i=1}^n (X_{k,i} - \mu_k)^2 - 2n(\bar{X}_k - \mu_k)^2 + n(\bar{X}_k - \mu_k)^2 \quad (2.29)$$

$$= \sum_{i=1}^n (X_{k,i} - \mu_k)^2 - n(\bar{X}_k - \mu_k)^2 \quad (2.30)$$

となる。よって、

$$s_k^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n (X_{k,i} - \mu_k)^2 - (\bar{X}_k - \mu_k)^2 \right) \quad (2.31)$$

と整理できる。

大数の弱法則より $(\bar{X}_k - \mu_k) \xrightarrow{p} 0$ であり、連続写像定理から $(\bar{X}_k - \mu_k)^2 \xrightarrow{p} 0$ である。また、

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n (X_{k,i} - \mu_k)^2 \right] = \mathbb{E}[(X_k - \mu_k)^2] = \text{Var}[X_k] = \sigma_k^2 \quad (2.32)$$

となるから、大数の弱法則より $\frac{1}{n} \sum_{i=1}^n (X_{k,i} - \mu_k)^2 \xrightarrow{p} \sigma_k^2$ である。

また、 $n \rightarrow \infty$ のとき $\frac{n}{n-1} \rightarrow 1$ であるから、連続写像定理より、

$$s_k^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n (X_{k,i} - \mu_k)^2 - (\bar{X}_k - \mu_k)^2 \right) \xrightarrow{p} \sigma_k^2 \quad (2.33)$$

である。

ここで、「統計学への確率論、その先へ」の定理 4.3.1 より、 $(s_1^2, s_2^2) \xrightarrow{p} (\sigma_1^2, \sigma_2^2)$ が成り立つ。再び連続写像定理より

$$R_n = \sqrt{\frac{s_1^2 + s_2^2}{\sigma_1^2 + \sigma_2^2}} \xrightarrow{p} \sqrt{\frac{\sigma_1^2 + \sigma_2^2}{\sigma_1^2 + \sigma_2^2}} = 1 \quad (2.34)$$

となる。

スラツキーの定理を用いて

$$t = \frac{U_n}{R_n} \xrightarrow{d} Z \quad (2.35)$$

となる。

これで、元のデータが正規分布に従っていなかったとしても、サンプルサイズが十分大きいのであれば、検定統計量は標準正規分布に従う確率変数に分布収束するとわかった。そのため、棄却域を与えるパーセント点は標準正規分布から与えれば良い。また、サンプルサイズが十分大きいのであれば、Welch-Satterthwaite の自由度も大きくなり、t 分布は標準正規分布で近似できる。これより、データが正規分布に従っていないがサンプルサイズが大きい時、特別に標準正規分布からパーセント点を求めずとも、t 分布から求めたパーセント点を用いれば良い。すなわち、Welch の t 検定をそのまま用いることができる。

3 ポアソン分布の差の検定

3.1 どのような検定か

ある事象の発生回数がポアソン分布に従うとし、各群で独立に同一の分布に従う確率変数を $X_{1,i} \sim \text{Po}(\lambda_1)$ ($i = 1, \dots, n_1$), $X_{2,i} \sim \text{Po}(\lambda_2)$ ($i = 1, \dots, n_2$) とする。このようなデータとして、例えばユーザーあたりの CV 数が考えられる。

$$\hat{\lambda}_1 = \frac{1}{n_1} \sum_{i=1}^{n_1} X_{1,i}, \quad \hat{\lambda}_2 = \frac{1}{n_2} \sum_{i=1}^{n_2} X_{2,i} \quad (3.1)$$

とすると、 $\mathbb{E}[X_{k,i}] = \lambda_k$, $\text{Var}[X_{k,i}] = \lambda_k$ より、

$$\mathbb{E}[\hat{\lambda}_k] = \lambda_k, \quad \text{Var}[\hat{\lambda}_k] = \frac{\lambda_k}{n_k} \quad (3.2)$$

となる。サンプルサイズが十分大きい場合、中心極限定理より $\hat{\lambda}_k \sim N(\lambda_k, \frac{\lambda_k}{n_k})$ が成り立ち、正規分布の再生性より $\hat{\lambda}_1 - \hat{\lambda}_2 \sim N(\lambda_1 - \lambda_2, \frac{\lambda_1}{n_1} + \frac{\lambda_2}{n_2})$ となる。

以上のことから、帰無仮説 H_0 を $\lambda_1 = \lambda_2$ とする仮説検定において、検定統計量は

$$Z = \frac{\hat{\lambda}_1 - \hat{\lambda}_2}{\sqrt{\frac{\hat{\lambda}_1}{n_1} + \frac{\hat{\lambda}_2}{n_2}}} \quad (3.3)$$

となる。対立仮説に対する棄却域と p 値の計算方法は表 3.1 の通りである。 z は正規分布に従う確率変数であり、 z_α は上側 $100\alpha\%$ を満たす点である。

表 3.1: ポアソン分布の差の検定における対立仮説と棄却域、p 値の計算方法

対立仮説	棄却域	p 値の計算方法
$\lambda_1 \neq \lambda_2$	$ Z > z_{\alpha/2}$	$2P(z > Z)$
$\lambda_1 > \lambda_2$	$Z > z_{\alpha}$	$P(z > Z)$
$\lambda_1 < \lambda_2$	$Z < -z_{\alpha}$	$P(z < Z)$

3.2 サンプルサイズ的设计

3.2.1 両側検定

対立仮説を $\lambda_1 \neq \lambda_2$ としたときのサンプルサイズ計算に用いる計算式を導出する。そのほかの検定と同様にして、

$$1 - \beta = P(Z > z_{\alpha/2}) \quad (3.4)$$

$$= P\left(\frac{\hat{\lambda}_1 - \hat{\lambda}_2}{\sqrt{\frac{\hat{\lambda}_1}{n_1} + \frac{\hat{\lambda}_2}{n_2}}} > z_{\alpha/2}\right) \quad (3.5)$$

$$= P\left(\frac{\hat{\lambda}_1 - \hat{\lambda}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\hat{\lambda}_1}{n_1} + \frac{\hat{\lambda}_2}{n_2}}} > z_{\alpha/2} - \frac{\mu_1 - \mu_2}{\sqrt{\frac{\lambda_1}{n_1} + \frac{\lambda_2}{n_2}}}\right) \quad (3.6)$$

これより、

$$-z_{\beta} = z_{\alpha/2} - \frac{\mu_1 - \mu_2}{\sqrt{\frac{\lambda_1}{n_1} + \frac{\lambda_2}{n_2}}} \quad (3.7)$$

が成り立つ。これを n_1 について解くことで、サンプルサイズの計算式を得る。

$$n_1 = \frac{(z_{\alpha/2} + z_{\beta})^2 (\lambda_1 + \frac{\lambda_2}{r})}{(\mu_1 - \mu_2)^2} \quad (3.8)$$

3.2.2 片側検定

両側検定の計算式における $z_{\alpha/2}$ に z_{α} を代入すれば良い。

4 同等性検定

4.1 どのような検定か

同等性検定は、2つの群に同等とみなせる程度の差しかないことを示すための検定である。2群の母平均 μ_1, μ_2 について、同等とみなせる差を Δ_l, Δ_u ($\Delta_l < \Delta_u$) とするとき、帰無仮説 H_0

と対立仮説 H_1 は

$$H_0 : \mu_1 - \mu_2 < \Delta_l \vee \mu_1 - \mu_2 > \Delta_u \quad (4.1)$$

$$H_1 : \Delta_l \leq \mu_1 - \mu_2 \leq \Delta_u \quad (4.2)$$

とする。帰無仮説を棄却するとき、同等とみなせる程度しか差がなかったと言える。

Welch の t 検定を用いることができ、検定統計量は

$$T_l = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_l}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}, \quad T_r = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_u}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (4.3)$$

である。 $\mu_1 - \mu_2 < \Delta_l$ に対する棄却域は $T > t_\alpha(\nu)$ 、 $\mu_1 - \mu_2 > \Delta_u$ に対する棄却域は $T < -t_\alpha(\nu)$ である。

4.2 サンプルサイズ的设计

Welch の t 検定と同様に求めることができる。まず、帰無仮説が $\mu_1 - \mu_2 < \Delta_l$ である場合を導出する。

$$1 - \beta = P(T > z_\alpha) \quad (4.4)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2 - \Delta_l}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} > z_\alpha\right) \quad (4.5)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} > z_\alpha - \frac{\mu_1 - \mu_2 - \Delta_l}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}\right) \quad (4.6)$$

これより、

$$-z_\beta = z_\alpha - \frac{\mu_1 - \mu_2 - \Delta_l}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (4.7)$$

となるため、 n_1 について解くことでサンプルサイズの計算式を得る。

$$n_1 = \frac{(z_{\alpha/2} + z_\beta)^2 \left(s_1^2 + \frac{s_2^2}{r}\right)}{(\mu_1 - \mu_2 - \Delta_l)^2} \quad (4.8)$$

帰無仮説が $\mu_1 - \mu_2 > \Delta_u$ である場合も同様に導出できる。

$$1 - \beta = P(T < -z_\alpha) \quad (4.9)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2 - \Delta_u}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} < -z_\alpha\right) \quad (4.10)$$

$$= P\left(\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} < -z_\alpha - \frac{\mu_1 - \mu_2 - \Delta_u}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}\right) \quad (4.11)$$

これより、

$$z_\beta = -z_\alpha - \frac{\mu_1 - \mu_2 - \Delta_u}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (4.12)$$

となるため、 n_1 について解くことでサンプルサイズの計算式を得る。

$$n_1 = \frac{(-z_{\alpha/2} - z_\beta)^2 \left(s_1^2 + \frac{s_2^2}{r}\right)}{(\mu_1 - \mu_2 - \Delta_u)^2} = \frac{(z_{\alpha/2} + z_\beta)^2 \left(s_1^2 + \frac{s_2^2}{r}\right)}{(\mu_1 - \mu_2 - \Delta_u)^2} \quad (4.13)$$

5 非劣性検定

5.1 どのような検定か

非劣性検定は、AB テストにおいて現行バージョンを群1、新たなバージョンを群2とした時、群2が群1から劣化していないかを確認するのに用いることができる。

2群の母平均 μ_1, μ_2 について、許容できる差を Δ_l とするとき、帰無仮説 H_0 と対立仮説 H_1 は

$$H_0 : \mu_1 - \mu_2 < \Delta_l \quad (5.1)$$

$$H_1 : \Delta_l \leq \mu_1 - \mu_2 \quad (5.2)$$

とする。帰無仮説を棄却するとき、許容できる程度の劣化しかなかったと言える。

Welch の t 検定を用いることができ、検定統計量は

$$T_l = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_l}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (5.3)$$

である。棄却域は $T > t_\alpha(\nu)$ である。

同等性検定のうち、lower equivalence bound に対する検定のみを行うと思えば良い。

5.2 サンプルサイズの設計

同等性検定における Δ_l の時の計算式と同じである。

6 マンホイットニーの U 検定

6.0.1 どのような検定か

「現代数理統計学」のセクション 12.2 に説明されている。値を元にランキングをつけて、順序を利用した検定統計量により検定を実施する。

6.0.2 サンプルサイズの計算

「Sample Size Determination for Some Common Nonparametric Tests」に書いてある。ただし、この論文は片側検定の式なので、両側検定に使う場合は z_α を $z_{\alpha/2}$ に変える必要がある。

7 多重比較の補正

7.1 Holm 法

7.1.1 検定の方法

多重比較における帰無仮説を $H_{0,i}$ ($i = 1, \dots, n$) とする。また、各検定における p 値は p_i で、単調増加するように並んでいるものとする。 $i = 1$ から検定を開始する。 $p_i < \frac{\alpha}{n+1-i}$ ならば $H_{0,i}$ を棄却し、 $i + 1$ に進める。 $H_{0,i}$ を棄却できない場合は検定を終了する。

7.1.2 FWER を有意水準以下に抑えられることの証明

標本空間 Ω を 1 回の実験で得られるデータ全体の集合（あるユーザーが何回 CV したなど）として、確率空間 $(\Omega, \mathcal{F}, P)$ を定義する。 $I = \{i | H_{0,i} \text{は真である}\}$ とし、 $m = |I|$ とする。

$i^* = \arg \min_{i \in I} p_i$ とする。 $i^* \leq n - m + 1$ より $\frac{1}{n+1-i^*} \leq \frac{1}{m}$ を得る。FWER は、少なくとも 1 回帰無仮説が真である場合に誤って棄却する確率である。Holm 法の検定方法より、少なくとも 1 回帰無仮説が真である場合に棄却されるためには、 H_{0,i^*} が棄却される必要がある。 H_{0,i^*} が棄却されなかった場合そこで検定が終了するため、他の帰無仮説も棄却されないからである。 H_{0,i^*} が棄却される条件は $p_{i^*} < \frac{\alpha}{n+1-i^*} \leq \frac{\alpha}{m}$ である。これより、

$$\text{FWER} \leq P\left(\min_{i \in I} p_i \leq \frac{\alpha}{m}\right) \quad (7.1)$$

となる。さらに整理して、

$$\text{FWER} \leq P\left(\min_{i \in I} p_i \leq \frac{\alpha}{m}\right) = P\left(\bigcup_{i \in I} \left\{p_i \leq \frac{\alpha}{m}\right\}\right) \leq \sum_{i \in I} P\left(\left\{p_i \leq \frac{\alpha}{m}\right\}\right) \leq m \frac{\alpha}{m} = \alpha \quad (7.2)$$

となる。ここでは以下を用いた。

1. 確率測度の劣加法性
2. 帰無仮説が真である場合に p 値は一様分布するため、 $P\left(\left\{p_i \leq \frac{\alpha}{m}\right\}\right) \leq \frac{\alpha}{m}$ であること

帰無仮説が真である時に p 値が一様分布することは、確率積分変換から導出することができる。「数理統計学の基礎」の命題 2.19 を参考にした。

7.1.3 Bonferroni 法に対する優位性

Bonferroni 法は、全ての帰無仮説に対して有意水準を α/n とする。Holm 法よりも各検定における有意水準が小さく、検出力に課題がある。Holm 法は FWER を有意水準 α 以下に抑えつつ、Bonferroni 法よりも高い検出力で検定が可能である。

参考文献

- [1] 東京大学教養学部統計学教室（編）『統計学入門 基礎統計学 I』東京大学出版会、1991 年。
<https://www.amazon.co.jp/dp/4130420658>
- [2] 久保川達也『現代数理統計学の基礎』共立出版、2017 年。<https://www.amazon.co.jp/dp/4320111664>
- [3] 竹村彰通（2020）『新装改訂版 現代数理統計学』学術図書出版社.
- [4] 日本統計学会 編（2023）『増訂版 日本統計学会公式認定 統計検定 1 級対応 統計学』東京図書.
- [5] 清水泰隆『統計学への確率論、その先へーゼロからの測度論的理解と漸近理論への架け橋』内田老鶴圃、2019 年。<https://www.amazon.co.jp/dp/B09HQGPM6L>
- [6] 永田靖『サンプルサイズの決め方 (統計ライブラリー)』朝倉書店、2003 年。<https://www.amazon.co.jp/dp/4254126654>
- [7] Ron Kohavi, Diane Tang, Ya Xu 著, 大杉直也 訳（2021）『A/B テスト実践ガイド ――真のデータドリブンへ至る信頼できる実験とは』アスキー・ドワンゴ.
- [8] Lakens, D. "Equivalence Tests: A Practical Primer for t Tests, Correlations, and Meta-Analyses." *Social Psychological and Personality Science* 8.4 (2017): 355-362. https://pmc.ncbi.nlm.nih.gov/articles/PMC5502906/pdf/10.1177_1948550617697177.pdf
- [9] Ahn, S., & Park, S. H. "Understanding equivalence and noninferiority testing." *Korean Journal of Pediatrics* 55.11 (2012): 403-405. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3510268/pdf/kjped-55-403.pdf>
- [10] Gottfried E. Noether (1987) "Sample Size Determination for Some Common Nonparametric Tests", *Journal of the American Statistical Association*, 82(398), 645-647.
- [11] emuyn. "同等性検定." <https://www.emuyn.net/stats/lecture/%E5%90%8C%E7%AD%89%E6%80%A7%E6%A4%9C%E5%AE%9A>

- [12] Robinson, T. S. "10 Econometric Theorems: Slutsky's Theorem." https://bookdown.org/ts_robinson1994/10EconometricTheorems/slutsky.html